UNIVERSIDAD NACIONAL AGRARIA

LA MOLINA

FACULTAD DE ECONOMÍA Y PLANIFICACIÓN

INFORME TÉCNICO

Curso:

CIENCIA DE DATOS 2

INTEGRANTES:

Anchante Fernandez, Marcello	**20211804**
Barrientos Benites, David José	**20211807**
Ramos Orue, Selene	**20220777**
Rios Vera, Sebastian	**20211828**

LIMA – PERÚ

2026

1. Introducción

En el Perú casi todos los gastos pequeños, como una farmacia, un menú, el grifo o una librería, se sustentan con una boleta o una factura. Desde 2019 la regla general es el comprobante electrónico, pero la SUNAT todavía acepta boletas impresas por imprentas autorizadas cuando el emisor no puede emitir en forma electrónica o está en una zona con poca conectividad (SUNAT, s. f.). Por eso conviven tres formatos: tickets impresos en papel térmico, que se borran con el tiempo; boletas electrónicas en PDF, cada empresa con un diseño distinto; y boletas de talonario llenadas a mano.

Estos comprobantes no solo sirven para cambiar un producto. Una persona natural puede deducir de su impuesto a la renta el 15 % de lo que gasta en restaurantes y hoteles, con un tope de 3 UIT, que en 2026 equivalen a S/ 16 500 (Diario Oficial El Peruano, 2026). Para que la deducción proceda, el comprobante debe ser electrónico y llevar el DNI del cliente en el campo "DNI"; si el número aparece en otro campo, la deducción no vale (SUNAT, s. f.). En una empresa pasa algo parecido: cada compra se registra en la contabilidad y se concilia con los pagos.

Para usar esos datos en un Excel o en un sistema contable, alguien tiene que copiar a mano el RUC, la serie, la fecha, el IGV y el total de cada comprobante. Es un trabajo lento y es fácil equivocarse en un dígito. El RUC tiene 11 dígitos y uno de ellos es un dígito verificador, así que un error al copiar lo vuelve inválido. Lo mismo pasa con el IGV: si no corresponde al 18 % de la operación gravada, el registro queda mal. Con boletas borrosas o fotos tomadas con el celular, torcidas o con sombra, copiar los datos es todavía más difícil.

Este proyecto prueba si se puede automatizar esa tarea con dos técnicas. La primera es el reconocimiento óptico de caracteres (OCR), que convierte la imagen del comprobante en texto. Se usó Tesseract, un motor de OCR de código abierto desarrollado en HP y liberado luego por Google (Smith, 2007). La segunda es el procesamiento de lenguaje natural (NLP), que limpia ese texto, busca los datos que pide la SUNAT, los valida con el dígito verificador del RUC y el cálculo del IGV, y clasifica el tipo de gasto.

El resultado es una aplicación web en Streamlit que recibe fotos o PDF y devuelve los datos ordenados. Se probó con 9 boletas electrónicas reales y 6 boletas de prueba que simulan fotos de mala calidad. Este informe describe los datos, los pasos del método, la aplicación , los resultados y lo que todavía falla.

2. Objetivos

Desarrollar una aplicación web en Streamlit que extraiga automáticamente los datos de boletas y facturas peruanas a partir de fotos o archivos PDF, usando reconocimiento óptico de caracteres (OCR) y procesamiento de lenguaje natural (NLP), para que esos datos se puedan registrar en un Excel o un sistema contable sin copiarlos a mano.

Objetivos específicos

- Armar un dataset propio de comprobantes peruanos, con 9 boletas electrónicas reales en PDF y 6 boletas de prueba que simulan fotos de mala calidad, para probar la aplicación con distintos formatos.
- Aplicar técnicas de preprocesamiento de imágenes (redimensionamiento, escala de grises, eliminación de ruido, mejora de contraste, corrección de inclinación y binarización) para mejorar la lectura del OCR.
- Extraer el texto de cada comprobante con Tesseract y medir la confianza de la lectura, para comparar los resultados con y sin preprocesamiento.
- Limpiar el texto extraído con técnicas básicas de NLP (corrección de símbolos, conversión a minúsculas, eliminación de caracteres especiales, tokenización y eliminación de stopwords), para dejarlo listo para el análisis.
- Extraer 7 campos de cada comprobante (tipo, serie y número, RUC, razón social, fecha, IGV y total) mediante reglas basadas en el formato de la SUNAT, y validarlos con el dígito verificador del RUC y el cálculo del IGV al 18 %.
- Clasificar cada comprobante en una de 13 categorías de gasto mediante un diccionario de palabras clave, y extraer sus palabras más representativas con TF-IDF.

- Evaluar la calidad del OCR y del análisis NLP con el número de campos extraídos, la confianza de la lectura y la exactitud de la clasificación, para identificar las limitaciones del sistema.

3. Datos

El dataset tiene 33 comprobantes:

Fuente	Cantidad	Formato	Emisores o rubros
Boletas electrónicas reales	14	PDF (ticket y A4, una de 2 páginas)	Tiendas Aruma (3), Yape Market (3), Mifarma, Promotick, Fundación para el Desarrollo Agrario
Boletas sintéticas	6	PNG	Pollería, grifo, botica, librería, tecnología, ferretería (negocios ficticios)
Fotos de boletas en papel	13	JPG	Tiendas y Markets

Las boletas reales corresponden a compras de los integrantes del grupo. Cubren cinco tipos de gasto: cuidado personal y belleza, entretenimiento, comida, educación y salud. Sus formatos cambian según la empresa. Las de Aruma tienen formato de ticket, las de Yape Market y

Promotick tienen formato A4 con los montos en una tabla, y una de Aruma ocupa 2 páginas, con el total en la segunda. Se guardaron en la carpeta `data/raw/` con nombres que indican el emisor y el rubro (por ejemplo, `pdf_aruma_belleza_01.pdf`).

El conjunto de prueba se generó con un script y simula fotos tomadas con celular: tiene ruido, sombra, bajo contraste e inclinación de hasta 4°. Como los PDF reales ya vienen limpios, este conjunto se usó para medir el efecto del preprocesamiento y para elegir sus parámetros

4. Metodología

Cada comprobante pasa por cuatro etapas. El código está escrito en Python y cada etapa es un módulo del proyecto:

A. Preprocesamiento de la imagen (src/preprocess.py, con OpenCV).
B. Reconocimiento óptico de caracteres con Tesseract (src/ocr.py).
C. Limpieza del texto (src/nlp.py).
D. Análisis NLP: extracción de entidades, validación, clasificación y palabras clave (src/nlp.py).

Los archivos PDF se convierten primero a imagen a 300 dpi con la librería PyMuPDF. Si un PDF tiene varias páginas, se leen todas y se analizan como un solo comprobante, porque en algunas boletas el total aparece en la última página.

4.1 Preprocesamiento de imágenes

Se aplicaron seis técnicas, en este orden:

Técnica	Cómo se aplicó	Valor por defecto
Redimensionamiento	Interpolación cúbica para ampliar la imagen	1600 px de ancho (2000 px en PDF)
Conversión a escala de grises	De tres canales de color a uno solo	—
Eliminación de ruido	Filtro non-local means	Intensidad h = 10
Mejora de contraste	CLAHE (ecualización de histograma adaptativa por bloques)	Límite 2.0, bloques de 8 × 8

Técnica	Cómo se aplicó	Valor por defecto
Corrección de inclinación	Perfil de proyección: se prueban ángulos de −10° a 10° y se elige el que deja las líneas de texto más marcadas	Pasos de 0.25°

El redimensionamiento se usa porque las boletas térmicas tienen letra pequeña, y Tesseract lee mejor cuando las letras son más grandes. CLAHE sube el contraste por zonas, así una sombra en un lado de la boleta no oscurece todo el texto. La binarización adaptativa calcula un umbral distinto para cada zona de la imagen, por eso funciona mejor que un umbral único (Otsu) cuando la iluminación no es pareja. Los valores de la binarización se eligieron después de comparar seis configuraciones sobre el conjunto de prueba (sección 6).

4.2 Reconocimiento óptico de caracteres (OCR)

Se usó la librería pytesseract con el motor Tesseract 5, el modelo de idioma español (`spa`) y el motor LSTM (`--oem 3`). El modo de segmentación de página (PSM) se elige según el tipo de archivo: PSM 4, que lee una sola columna, para fotos de tickets; y PSM 3, que detecta la distribución de la página, para PDF en formato A4 con varias columnas. Con la función `image_to_data` se obtiene la confianza de cada palabra reconocida, de 0 a 100, y se calcula el promedio por comprobante.

Se eligió Tesseract frente a EasyOCR, PaddleOCR y TrOCR porque es liviano y se puede instalar en Streamlit Cloud con un solo archivo de configuración. EasyOCR y PaddleOCR necesitan librerías de más de 1 GB, y TrOCR lee una sola línea de texto por vez.

4.3 Limpieza del texto

Este es el resultado de cada paso sobre una línea de ejemplo:

Paso	Resultado
Texto del OCR	2 PARACETAMOL 5OOMG TABLETA X10 6 .00
Corrección de espacios y símbolos	2 PARACETAMOL 500MG TABLETA X10 6.00
Conversión a minúsculas	2 paracetamol 500mg tableta x10 6.00

Paso	Resultado
Eliminación de caracteres especiales	paracetamol mg tableta x
Tokenización	[paracetamol, mg, tableta, x]
Eliminación de stopwords	[paracetamol, tableta]

La corrección de símbolos arregla errores típicos del OCR: la letra O leída en lugar del cero, la letra B leída como 8 en la serie (8001 en vez de B001) o “S /” en lugar de “S/”. Para eliminar stopwords se usaron dos listas escritas a mano: 92 palabras vacías del español (de, la, que, para) y 113 palabras que aparecen en casi todos los comprobantes y no ayudan a distinguir un gasto de otro (ruc, igv, total, sunat, gravada, tarjeta).

Las entidades se buscan en el texto corregido, que conserva los números y las mayúsculas. El texto limpio, sin números, se usa para la clasificación y las palabras clave.

4.4 Aplicación de NLP

Se aplicaron cuatro técnicas de procesamiento de lenguaje natural.

Extracción de entidades. Con expresiones regulares se buscan el tipo de comprobante, la serie y el número, el RUC del emisor, la razón social, el DNI del cliente, la fecha, la moneda, la operación gravada, el IGV y el total. El tipo se decide por la primera letra de la serie: B para boleta y F para factura. También se aceptan las series numéricas de las boletas de talonario (por ejemplo, 001-0000418). En los PDF de formato A4, las etiquetas de los montos están en una fila y los valores en la fila de abajo, así que cada valor se empareja con su etiqueta según la posición de la columna.

Validación. El RUC se comprueba con su dígito verificador, usando el método de módulo 11. Se multiplican los primeros 10 dígitos por los pesos 5, 4, 3, 2, 7, 6, 5, 4, 3, 2 y se suman los resultados (s). El dígito verificador es:

$$s = \sum_{i=1}^{10} d_i \, w_i, \qquad dv = 11 - (s \bmod 11), \qquad 10 \to 0,\ 11 \to 1$$

Si no coincide con el último dígito del RUC, la aplicación muestra una alerta. También se revisa que el IGV sea igual al 18 % de la operación gravada y que la suma de ambos dé el total. Si el OCR no logra leer el IGV, se calcula como total menos operación gravada y se muestra una

alerta. Si no se encuentra ni RUC ni serie, la aplicación avisa que el documento no parece un comprobante SUNAT.

Clasificación temática. Cada comprobante se asigna a una de 13 categorías de gasto (por ejemplo, alimentos y restaurantes, salud y farmacia, cuidado personal y belleza, educación o entretenimiento) usando un diccionario de 266 palabras clave. El puntaje de cada categoría es la cantidad de palabras del comprobante que pertenecen a ella. Las palabras de las líneas de productos cuentan doble, porque indican qué se compró, mientras que el encabezado solo indica dónde. Para tolerar errores de escritura se usa coincidencia aproximada con la librería difflib; por ejemplo, "gasesosas" se reconoce como "gaseosas". La confianza de la clasificación es:

$$\text{confianza} = \frac{\text{puntaje de la categoría ganadora}}{\sum \text{puntajes de todas las categorías}}$$

Palabras clave y nube de palabras. Se calculan las palabras más frecuentes de cada comprobante y las de mayor peso TF-IDF dentro del lote, que son las que distinguen a un comprobante de los demás:

$$\text{tfidf}(t, d) = \text{tf}(t, d) \times \left(\ln \frac{1 + n}{1 + \text{df}(t)} + 1 \right)$$

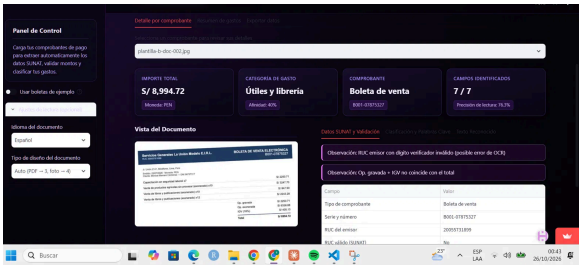
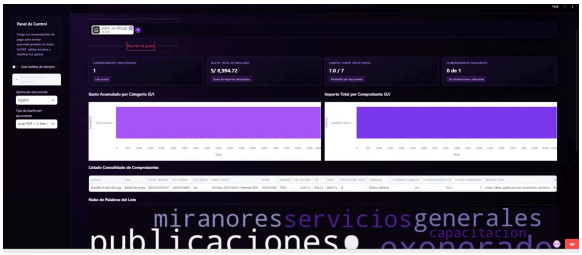
donde tf es la frecuencia de la palabra t en el comprobante d, n es el número de comprobantes y df es el número de comprobantes que contienen la palabra. Por último, se genera una nube de palabras para cada comprobante y otra para todo el lote.

5. Aplicación en Streamlit

La aplicación se llama "Lector y Analizador de Comprobantes de Pago" y está desplegada en Streamlit Community Cloud: https://ocr-boletas.streamlit.app. Se puede usar desde cualquier navegador, sin instalar nada. El código está en el repositorio de GitHub del proyecto, y la aplicación se actualiza sola cada vez que se sube un cambio. Tesseract y el modelo en español se instalan en el servidor con un archivo de configuración (`packages.txt`).

La pantalla tiene un panel de control a la izquierda y tres pestañas en el centro.

Parte	Qué muestra o permite hacer
Panel de control	Interruptor para usar las boletas del conjunto de prueba. En "Ajustes de lectura" se elige el idioma del documento y el tipo de diseño (modo de segmentación del OCR); por defecto

Parte	Qué muestra o permite hacer
	está en automático: PSM 3 para PDF y PSM 4 para fotos
Carga de archivos	Se arrastran o seleccionan una o varias imágenes (JPG, PNG) o documentos PDF
Pestaña “Detalle por comprobante” 	Se elige un comprobante y se ven cuatro indicadores: importe total, categoría de gasto (con su afinidad en %), tipo de comprobante con su serie, y campos identificados de 7 (con la precisión de lectura del OCR). Debajo aparece la imagen del documento y tres subpestañas: “Datos SUNAT y Validación”, con la tabla de campos extraídos y las observaciones; “Clasificación y Palabras Clave”; y “Texto Reconocido”, con el texto que leyó el OCR
Pestaña “Resumen de gastos” 	Indicadores del lote (comprobantes procesados, gasto total acumulado, promedio de campos SUNAT detectados y comprobantes sin observaciones), gráfico de gasto acumulado por categoría, gráfico de importe por comprobante, listado consolidado de todos los comprobantes y nube de palabras del lote
Pestaña “Exportar datos”	Descarga de los resultados en tres formatos: hoja de cálculo CSV compatible con Excel, datos estructurados en JSON y textos extraídos en ZIP. También muestra el diccionario de categorías y palabras clave
Panel de control	Interruptor para usar las boletas del conjunto de prueba. En “Ajustes de lectura” se elige el idioma del documento y el tipo de diseño (modo de segmentación del OCR); por defecto

Parte	Qué muestra o permite hacer
	está en automático: PSM 3 para PDF y PSM 4 para fotos
Carga de archivos	Se arrastran o seleccionan una o varias imágenes (JPG, PNG) o documentos PDF

Las observaciones son la parte de validación. Si el dígito verificador del RUC no coincide, la aplicación avisa que puede ser un error del OCR. Si la operación gravada más el IGV no da el total, también lo indica. Si el documento no tiene RUC ni serie, avisa que no parece un comprobante SUNAT. Así el usuario sabe qué datos revisar a mano antes de usarlos.

Para medir el desempeño de todo el dataset de una vez se usa un script aparte (tools/evaluar.py), que procesa todos los archivos de una carpeta y guarda los resultados en una tabla (resultados/evaluacion.csv).

6. Pruebas y resultados

El sistema extrajo los 7 campos en los 15 comprobantes del dataset y clasificó bien el tipo de gasto en 14 de ellos. El preprocesamiento fue decisivo en las imágenes del conjunto de prueba, pero no cambió los resultados de los PDF.

Se usaron tres medidas:

- **Campos extraídos (de 7):** cuántos de los 7 campos (tipo, serie, RUC, razón social, fecha, IGV y total) se encontraron.
- **Confianza del OCR:** el promedio de la confianza de Tesseract en cada palabra, de 0 a 100.
- **Exactitud de la clasificación:** cuántos comprobantes quedaron en la categoría de gasto correcta, revisando cada uno a mano.

6.1 Elección del preprocesamiento

Se compararon seis configuraciones de preprocesamiento sobre las 6 imágenes del conjunto de prueba. La medida principal fue el número de campos extraídos; la confianza del OCR se usó como apoyo.

Configuración	Confianza OCR (%)	Campos extraídos (de 7)
Sin preprocesar	85.9	3.7
Grises + ruido + CLAHE, sin binarizar	80.0	6.0
Binarización Otsu	79.9	5.8
Filtro de mediana + Otsu	71.7	4.3
Adaptativa (bloque 31, C = 15)	86.3	6.8
Adaptativa (bloque 41, C = 10)	91.5	7.0

La binarización adaptativa con bloque 41 y C = 10 fue la única que extrajo los 7 campos en las 6 imágenes, y por eso quedó como configuración por defecto. La tabla también muestra que la confianza sola no basta para elegir. La configuración sin binarizar tiene menor confianza que la imagen original (80.0 % frente a 85.9 %), pero recupera muchos más campos (6.0 frente a 3.7).

6.2 Resultados por tipo de archivo

Medida	Conjunto de prueba	Boletas reales
Confianza OCR sin preprocesar (%)	85.9	90.5
Confianza OCR con preprocesamiento (%)	91.5	89.6
Campos extraídos sin preprocesar (de 7)	3.7	7.0
Campos extraídos con preprocesamiento (de 7)	7.0	7.0
RUC con dígito verificador válido	6 de 6	9 de 9
Categoría de gasto correcta	6 de 6	8 de 9

En las imágenes del conjunto de prueba, el preprocesamiento casi duplicó los campos extraídos, de 3.7 a 7.0. Sin preprocesar, Tesseract perdía casi toda la cabecera de la boleta (razón social, RUC, serie y fecha) y los montos del final. En los PDF reales no hubo diferencia en los campos, y la confianza bajó un poco (de 90.5 % a 89.6 %). Esto pasa porque los PDF electrónicos ya son imágenes limpias y rectas, y el preprocesamiento no tiene nada que corregir.

El IGV coincidió con el 18 % de la operación gravada en los 13 comprobantes donde se pudo comprobar. En los otros dos no aplicaba la validación. La boleta de la Fundación para el Desarrollo Agrario está exonerada de IGV, y en una boleta de Yape Market el OCR leyó "GV." en vez de "I.G.V.", así que el IGV se calculó como total menos operación gravada.

6.3 Clasificación de las boletas reales

Boleta	Categoría asignada	¿Correcta?
Tiendas Aruma (3 boletas)	Cuidado personal y belleza	Sí
Mifarma (limpiador facial)	Cuidado personal y belleza	Sí
Yape Market (entrada de cine)	Entretenimiento	Sí
Promotick (entradas)	Entretenimiento	Sí
Yape Market (combo con gaseosas)	Alimentos y restaurantes	Sí
Fundación para el Desarrollo Agrario (curso de inglés)	Educación	Sí
Yape Market (cupón)	Otros	No

La única boleta mal clasificada es un cupón de Yape Market cuya descripción de producto es un correo electrónico. Como no tiene palabras que indiquen qué se compró, quedó en "Otros". En el caso de Mifarma ayudó que las palabras de las líneas de productos pesen el doble. La boleta menciona el local "La Fontana Tottus", que habría sumado a la categoría supermercado, pero el producto (un limpiador CeraVe) pesó más y la boleta quedó bien clasificada.

6.4 Pruebas con documentos escritos a mano

También se probó la aplicación con dos fotos de documentos en papel llenados a mano. En una boleta de talonario se extrajeron bien los 4 campos impresos (tipo, serie, RUC y razón social), pero no la fecha ni el total, que estaban escritos a mano. En una proforma de una óptica, que no es un comprobante SUNAT, la aplicación no encontró RUC ni serie y mostró la alerta correspondiente. Estas pruebas muestran que el sistema funciona con texto impreso, pero no con texto manuscrito.

7. Conclusiones

Se desarrolló una aplicación web en Streamlit que lee boletas y facturas peruanas a partir de fotos o archivos PDF, extrae sus datos principales y los deja listos para descargar en Excel. La aplicación está desplegada en internet y se puede usar sin instalar nada.

El preprocesamiento de imágenes es necesario cuando el comprobante viene de una foto. En el conjunto de prueba, los campos extraídos subieron de 3.7 a 7.0 de 7, y la confianza del OCR de 85.9 % a 91.5 %. La técnica que más influyó fue la binarización adaptativa, que maneja mejor las sombras que un umbral único. En los PDF electrónicos el preprocesamiento no mejoró el resultado, porque esas imágenes ya vienen limpias.

Tesseract, junto con reglas basadas en el formato de la SUNAT, permitió extraer los 7 campos en los 15 comprobantes del dataset. Las reglas tuvieron que ajustarse con las boletas reales, por ejemplo para leer los montos en formato de tabla o juntar las páginas de un PDF de dos hojas.

La validación del RUC con su dígito verificador y del IGV con el 18 % de la operación gravada permite detectar errores de lectura sin revisar cada comprobante a mano. La aplicación avisa cuando un dato no cuadra, y así el usuario sabe qué revisar.

La clasificación del gasto por diccionario de palabras clave acertó en 14 de los 15 comprobantes. Funciona bien cuando la boleta describe el producto comprado, y falla cuando la descripción no tiene palabras útiles, como en un cupón cuya descripción era un correo electrónico.

El sistema funciona con texto impreso, pero no con texto escrito a mano. En una boleta de talonario se leyeron bien los datos impresos (tipo, serie, RUC y razón social), pero no la fecha ni el total, que estaban escritos a mano.

8. Referencias

Diario Oficial El Peruano. (2026, 22 de julio). *Fiestas Patrias 2026: aprovecha tus consumos para pagar menos impuesto a la renta*. https://elperuano.pe/noticia/300825-fiestas-patrias-2026-aprovecha-tus-consumos-para-pagar-menos-impuesto-a-la-renta

Smith, R. (2007). An overview of the Tesseract OCR engine. En *Ninth International Conference on Document Analysis and Recognition (ICDAR 2007)* (Vol. 2, pp. 629-633). IEEE.

SUNAT. (s. f.). *Gastos en restaurantes y hoteles*. Orientación SUNAT. https://orientacion.sunat.gob.pe/node/450